PRISM：当前实验流程

Prospective-Regret-Aware Preference Sampling for Reward Modeling in RLHF

阶段 A　无标签采样设计

A1. 固定设置　SFT/reference policy π_0、EOS 特征提取器 ϕ、prompt 分布 ρ 及 PPO/LoRA 训练配置。

A2. SFT rollout 与候选比较　对每个 prompt 生成候选回答，缓存 EOS 特征和序列对数概率：

$$\phi_{ij} = \phi(x_i, y_{ij}), \quad \ell_{ij} = \log \pi_0(y_{ij} \mid x_i), \qquad e = (x, y_a, y_b), \quad v_e = \phi(x, y_a) - \phi(x, y_b).$$

A3. Log-linear policy 代理　利用岭回归拟合 SFT 的相对 log-probability：

$$\hat{b}_0 = \arg\min_b \left\{ \sum_{i,j} \left[b^\top \phi_{ij} - (\ell_{ij} - \bar{\ell}_i) \right]^2 + \alpha \|b\|_2^2 \right\}, \qquad \tilde{\pi}_{ij} = \mathrm{softmax}_j(\hat{b}_0^\top \phi_{ij}).$$

A4. Prospective 几何代理　以 log-linear policy 的特征空间 Fisher 作为 K 的计算代理：

$$\hat{\mu}_i = \sum_j \tilde{\pi}_{ij} \phi_{ij}, \qquad \hat{K} = \frac{1}{M} \sum_{i=1}^{M} \sum_j \tilde{\pi}_{ij} (\phi_{ij} - \hat{\mu}_i)(\phi_{ij} - \hat{\mu}_i)^\top.$$

A5. 最优采样设计　加阻尼、不设覆盖约束；用 Frank–Wolfe 求采样分布：

$$A_\lambda(q) = \lambda I + \sum_{e \in \mathcal{E}} q_e v_e v_e^\top, \qquad \boxed{\hat{q} \in \arg\min_{q \in \Delta_m} \mathrm{tr}\big(\hat{K} A_\lambda(q)^{-1}\big)}.$$

阶段 B　偏好标注与 Reward Modeling

B1. 偏好标注　按 $\hat{q}$ 独立采样比较边，用固定 LLM Judge 产生二元标签 $a_i \in \{0, 1\}$；不需要观测 r^*。

B2. Bradley–Terry MLE　冻结 EOS 表示，仅训练线性 Reward Head：

$$\boxed{\hat{w}_n \in \arg\min_w \frac{1}{n} \sum_{i=1}^{n} \left[\log\left(1 + e^{v_{e_i}^\top w}\right) - a_i v_{e_i}^\top w \right]}, \qquad R_{\hat{w}_n}(x, y) = \hat{w}_n^\top \phi(x, y).$$

阶段 C　Policy 后训练与评估

C1. Policy optimization　以相同 SFT 为起点，固定 PPO/LoRA 超参数、KL 系数、训练 prompt 与训练预算，仅替换由不同 sampling 训练的 Reward。

C2. 对照方法　Uniform、Reward A-optimal、Uncertainty、PRISM；保持相同候选池、LLM Judge、标签预算、BT MLE 及下游训练配置。

C3. 独立评估　主指标：**Win Rate、Benchmark**；控制指标：**KL divergence**。报告 Label Budget–Policy Quality 与 Win Rate–KL 曲线。

研究对象：真实局部 Prospective regret；数值实现：log-linear 代理 $\hat{K}$、阻尼设计目标。实验主要自变量为 sampling distribution，其余训练与评估条件固定。